


# ECONOMETRÍA BÁSICA

## CAPÍTULO 04: MODELO DE REGRESIÓN LINEAL MÚLTIPLE-INFERENCIA

José Valderrama & Freddy Rojas

[jtvalderrama@gmail.com](mailto:jtvalderrama@gmail.com) & [frojasca@gmail.com](mailto:frojasca@gmail.com) 

Universidad Católica Santo Toribio de Mogrovejo

Septiembre de 2021

# CONTENIDO

- 1 DISTRIBUCIONES MUESTRALES DE LOS ESTIMADORES MCO
- 2 PRUEBA DE HIPÓTESIS SOBRE UN SOLO PARÁMETRO DE POBLACIÓN: LA PRUEBA T
  - t-student
  - P-Value
- 3 INTERVALOS DE CONFIANZA
- 4 PRUEBA DE HIPÓTESIS SOBRE UNA COMBINACIÓN LINEAL SIMPLE DE PARÁMETROS
- 5 PRUEBA DE RESTRICCIONES LINEALES MÚLTIPLES: LA PRUEBA F
  - Prueba F
  - P-value
- 6 INFORME DE RESULTADOS DE REGRESIÓN

# CONTENIDO

- 1 DISTRIBUCIONES MUESTRALES DE LOS ESTIMADORES MCO
- 2 PRUEBA DE HIPÓTESIS SOBRE UN SOLO PARÁMETRO DE POBLACIÓN: LA PRUEBA T
  - t-student
  - P-Value
- 3 INTERVALOS DE CONFIANZA
- 4 PRUEBA DE HIPÓTESIS SOBRE UNA COMBINACIÓN LINEAL SIMPLE DE PARÁMETROS
- 5 PRUEBA DE RESTRICCIONES LINEALES MÚLTIPLES: LA PRUEBA F
  - Prueba F
  - P-value
- 6 INFORME DE RESULTADOS DE REGRESIÓN

# SUPUESTO PARA LA INFERENCIA

- **Suposición RLM6:** Normalidad. Con el fin de probar hipótesis se necesita agregar un supuesto adicional a los cinco supuestos ya vistos:  $u \sim N(0, \sigma^2)$  El error poblacional se distribuye como un normal con media cero y varianza  $\sigma^2$
- Lo anterior implica que

$$y/x \sim N(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k, \sigma^2)$$

- También  $\hat{\beta}_j = N(\beta_j, \text{Var}(\hat{\beta}_j))$ , por lo que estandarizando se tiene:

$$\frac{\hat{\beta}_j - \beta_j}{\text{Es}(\hat{\beta}_j)} \sim N(0, 1)$$

# SUPUESTO PARA LA INFERENCIA

- **Suposición RLM6:** Normalidad. Con el fin de probar hipótesis se necesita agregar un supuesto adicional a los cinco supuestos ya vistos:  $u \sim N(0, \sigma^2)$  El error poblacional se distribuye como un normal con media cero y varianza  $\sigma^2$
- Lo anterior implica que

$$y/x \sim N(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k, \sigma^2)$$

- También  $\hat{\beta}_j = N(\beta_j, \text{Var}(\hat{\beta}_j))$ , por lo que estandarizando se tiene:

$$\frac{\hat{\beta}_j - \beta_j}{\text{Es}(\hat{\beta}_j)} \sim N(0, 1)$$

# SUPUESTO PARA LA INFERENCIA

- **Suposición RLM6:** Normalidad. Con el fin de probar hipótesis se necesita agregar un supuesto adicional a los cinco supuestos ya vistos:  $u \sim N(0, \sigma^2)$  El error poblacional se distribuye como un normal con media cero y varianza  $\sigma^2$
- Lo anterior implica que

$$y/x \sim N(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k, \sigma^2)$$

- También  $\hat{\beta}_j = N(\beta_j, \text{Var}(\hat{\beta}_j))$ , por lo que estandarizando se tiene:

$$\frac{\hat{\beta}_j - \beta_j}{\text{Es}(\hat{\beta}_j)} \sim N(0, 1)$$

# SUPUESTO PARA LA INFERENCIA

- **Suposición RLM6:** Normalidad. Con el fin de probar hipótesis se necesita agregar un supuesto adicional a los cinco supuestos ya vistos:  $u \sim N(0, \sigma^2)$  El error poblacional se distribuye como un normal con media cero y varianza  $\sigma^2$
- Lo anterior implica que

$$y/x \sim N(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k, \sigma^2)$$

- También  $\hat{\beta}_j = N(\beta_j, \text{Var}(\hat{\beta}_j))$ , por lo que estandarizando se tiene:

$$\frac{\hat{\beta}_j - \beta_j}{\text{Es}(\hat{\beta}_j)} \sim N(0, 1)$$

- $$y/x \sim N(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k, \sigma^2)$$

- $$\frac{\hat{\beta}_j - \beta_j}{Es(\hat{\beta}_j)} \sim N(0, 1)$$



# CONTENIDO

- 1 DISTRIBUCIONES MUESTRALES DE LOS ESTIMADORES MCO
- 2 PRUEBA DE HIPÓTESIS SOBRE UN SOLO PARÁMETRO DE POBLACIÓN: LA PRUEBA T
  - t-student
  - P-Value
- 3 INTERVALOS DE CONFIANZA
- 4 PRUEBA DE HIPÓTESIS SOBRE UNA COMBINACIÓN LINEAL SIMPLE DE PARÁMETROS
- 5 PRUEBA DE RESTRICCIONES LINEALES MÚLTIPLES: LA PRUEBA F
  - Prueba F
  - P-value
- 6 INFORME DE RESULTADOS DE REGRESIÓN

# CONTENIDO

- 1 DISTRIBUCIONES MUESTRALES DE LOS ESTIMADORES MCO
- 2 PRUEBA DE HIPÓTESIS SOBRE UN SOLO PARÁMETRO DE POBLACIÓN: LA PRUEBA T
  - t-student
  - P-Value
- 3 INTERVALOS DE CONFIANZA
- 4 PRUEBA DE HIPÓTESIS SOBRE UNA COMBINACIÓN LINEAL SIMPLE DE PARÁMETROS
- 5 PRUEBA DE RESTRICCIONES LINEALES MÚLTIPLES: LA PRUEBA F
  - Prueba F
  - P-value
- 6 INFORME DE RESULTADOS DE REGRESIÓN

# INFERENCIA 1: PRUEBA DE HIPÓTESIS PARA UNA ÚNICA COMBINACIÓN LINEAL DE COEFICIENTES

Consideremos nuevamente el siguiente modelo (o PGD) con una constante y más de un regresor

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + u_i$$

La inferencia es el proceso de realizar una prueba estadística; nos interesa la importancia de los efectos sobre la variable dependiente. En particular, el coeficiente de interés es el efecto de  $X_2$  sobre  $Y$ . El efecto de  $X_1$  e  $Y$  es necesario porque eso nos permite controlar otros efectos. Por ejemplo

$$H_0 : \beta_2 = 0$$

$$H_a : \beta_2 \neq 0$$

por tanto, podemos centrarnos sólo en algún parámetro de interés, en este caso  $\beta_2$ . *[Pregunta: ¿Por qué deberíamos mantener en el análisis la variable  $X_1$ ? Son controles].*

# ANTES DE LA INFERENCIA

Cuando configuramos un modelo, tenemos los siguientes tipos de regresores:

- Regresores o variables de interés (relacionadas con la política).
- Variables de control.

Si alguna variable no se puede clasificar en las categorías anteriores, no la considere en su análisis.

## ¿Z O T-STUDENT?

Ya hemos discutido este tema con respecto a Z o t-student. Básicamente, debemos elegir la estadística según el número de observaciones bajo análisis. Una regla simple es: una muestra pequeña tiene menos de 150 observaciones; en ese caso nuestro análisis considera el t-student. La estadística es:

$$t_{cal} = \frac{\text{Estimador} - \text{Prueba de hipótesis}}{\text{Error estandar del estimador}}$$

por ejemplo.

$$t_{cal} = \frac{\hat{\beta}_2 - 0}{S.E(\hat{\beta}_2)}$$

luego contrastamos esa *t realmente calculada* con valores críticos o simplemente calculamos el *p-value* asociado a esa prueba; es decir,  $2Pr(t > |t_{cal}|)$

# T-STUDENT

- Aunque el  $\hat{\beta}_j$  teóricamente sigue una distribución normal, al depender de  $\sigma^2$  (parámetro no conocido) hace que el uso del estimador  $\hat{\sigma}^2 = SRC/(n - k - 1)$  cambie la distribución del parámetro.
- Conociendo la distribución se pueden probar diversas hipótesis como  $H_0 : \beta_j = 0$  en cuyo caso, si se prueba esa hipótesis la variable  $x_j$  no tiene efecto sobre  $y$  controlando por las otras  $x's$
- El  $t$  estadístico para dicha hipótesis sería  $t_{\beta_j} \equiv \frac{\hat{\beta}_j - 0}{Se(\hat{\beta}_j)}$  que sigue una distribución T de student con  $n - k - 1$  grados de libertad.
- Aunque con muestras grandes la T de student se comporta como una normal. Específicamente cuando  $n - k - 1 > 120$  se puede usar una normal para los valores críticos.


# T-STUDENT

- Además de la hipótesis nula ( $H_0$ ) para completar la prueba estadística se necesita de una hipótesis alternativa ( $H_1$ ) y de un nivel de significancia.
- $H_1$  puede ser de unilateral o de un lado o bilateral o de dos lados
- Unilateral:  $\beta_j > 0$  o  $\beta_j < 0$
- Bilateral:  $\beta_j \neq 0$
- El nivel de significancia es la probabilidad de cometer un error de tipo I, los valores frecuentemente elegidos son de 1, 5 y 10 por ciento.

# T-STUDENT

$$H_0 : \beta_j = 0 \text{ y } H_1 : \beta_j \neq 0$$

Si  $t_{\beta_j} > |Crit|$ , entonces se rechaza la hipótesis nula  $H_0$ . Donde  $Crit$  se obtiene de tablas estadísticas necesitando para ello el nivel de significancia a utilizar ( $\alpha$ ) y el número de grados de libertad  $n - k - 1$





# T-STUDENT

- Si se rechaza la  $H_0$  lo que típicamente se dice es que la variable  $x_j$  es estadísticamente significativa al nivel de significancia de  $\alpha$
- Si no se rechaza la  $H_0$  lo que típicamente se dice es que la variable  $x_j$  es estadísticamente no significativa al nivel de significancia de  $\alpha$
- Aunque se vio el caso de  $H_0 : \beta_j = 0$  en general se puede probar la hipótesis:  $H_0 : \beta_j = a_j$ , en cuyo caso el t-estadístico quedaría definido por:  $t = \frac{\hat{\beta}_j - a_j}{Se(\hat{\beta}_j)}$

## T-STUDENT: EJEMPLO

Podemos incluir en nuestro análisis de inferencia alguna combinación lineal de parámetros. Por ejemplo, consideremos una función de producción para la economía de EE. UU.

$$Q = e^{\alpha_0} K^{\alpha_k} L^{\alpha_l}$$

donde  $\hat{\alpha}_k = 0,632$  y  $\hat{\alpha}_l = 0,452$ . Adicionalmente, tenemos la siguiente información:  $cov(\hat{\alpha}_k, \hat{\alpha}_l) = 0,055$ ,  $std(\hat{\alpha}_k) = 0,257$  y  $std(\hat{\alpha}_l) = 0,219$ . Evaluamos si  $\hat{\alpha}_k$  son idénticos en términos estadísticos

$$t_{cal} = \frac{\hat{\alpha}_k - \hat{\alpha}_l}{S.E(\hat{\alpha}_k - \hat{\alpha}_l)}$$

o si existe evidencia de retornos constantes a escala

$$t_{cal} = \frac{\hat{\alpha}_k + \hat{\alpha}_l - 1}{S.E(\hat{\alpha}_k + \hat{\alpha}_l - 1)}$$

luego contrastamos esa *t realmente calculada* con valores críticos o simplemente calculamos el *p-value* asociado a esa prueba; es decir,  
 $2Pr(t > |t_{cal}|)$

## T-STUDENT: RESUMEN DE PASOS

- Calcular las estimaciones de MCO.
- Calcular el error estándar de las combinaciones lineales de parámetros.
- Calcular la estadística t-student o t "*realmente calculada*".
- Calcular el p-value o simplemente concluya utilizando valores críticos.
- La interpretación es muy importante, ¡no te pierdas ese paso !.

# CONTENIDO

- 1 DISTRIBUCIONES MUESTRALES DE LOS ESTIMADORES MCO
- 2 PRUEBA DE HIPÓTESIS SOBRE UN SOLO PARÁMETRO DE POBLACIÓN: LA PRUEBA T
  - t-student
  - P-Value
- 3 INTERVALOS DE CONFIANZA
- 4 PRUEBA DE HIPÓTESIS SOBRE UNA COMBINACIÓN LINEAL SIMPLE DE PARÁMETROS
- 5 PRUEBA DE RESTRICCIONES LINEALES MÚLTIPLES: LA PRUEBA F
  - Prueba F
  - P-value
- 6 INFORME DE RESULTADOS DE REGRESIÓN

# P-VALUE

- Además de la prueba T y el intervalo de confianza existe un tercer enfoque para evaluar la significancia individual de los parámetros
- El P-value o valor P es el nivel exacto de significancia y esta definido como el nivel más bajo de significancia al cual puede rechazarse una hipótesis nula
- Como regla práctica si el P-value es menor a 0.05 entonces se dice que se rechaza la nula a un nivel de significancia del 5 por ciento
- La ventaja del uso de este indicador es que no requiere observar ninguna tabla estadística, sólo comparar el P-value con el nivel de significancia deseado.

# CONTENIDO

- 1 DISTRIBUCIONES MUESTRALES DE LOS ESTIMADORES MCO
- 2 PRUEBA DE HIPÓTESIS SOBRE UN SOLO PARÁMETRO DE POBLACIÓN: LA PRUEBA T
  - t-student
  - P-Value
- 3 INTERVALOS DE CONFIANZA
- 4 PRUEBA DE HIPÓTESIS SOBRE UNA COMBINACIÓN LINEAL SIMPLE DE PARÁMETROS
- 5 PRUEBA DE RESTRICCIONES LINEALES MÚLTIPLES: LA PRUEBA F
  - Prueba F
  - P-value
- 6 INFORME DE RESULTADOS DE REGRESIÓN

# INTERVALOS DE CONFIANZA

- Otra forma de probar una hipótesis es construyendo intervalos de confianza usando el mismo valor crítico empleado para la prueba
- $\hat{\beta}_j \pm \text{Crit} * \text{Se}(\hat{\beta}_j)$ ,
- Donde *Crit* es el percentil  $(1 - \frac{\alpha}{2})$  en una distribución  $t_{n-k-1}$  bilateral

# UN INTERVALO DE CONFIANZA

- Se construye un intervalo de confianza alrededor de la estimación  $\hat{\beta}$  y ese conjunto indica todos los valores posibles donde se encuentra el valor real de la media poblacional o del parámetro (o estimación insesgada); por supuesto con alguna probabilidad de ocurrencia.
- Las probabilidades estándar son 99, 95 y 90 %.
- Un intervalo de confianza no significa precisión, significa confianza donde se encuentra el verdadero parámetro.
- Un enunciado "*Un 95 % de intervalo de confianza bilateral para  $\beta$  es un intervalo construido de modo que contenga el valor verdadero de  $\beta$  en el 95 % de todas las muestras aleatorias posibles*".



# UNA NOTACIÓN ALTERNATIVA PARA INTERVALOS DE CONFIANZA

Aquí una alternativa y asumiendo normalidad

$$90 \% \text{ I.C. para } \beta_2 = [\hat{\beta}_2 \pm t_{gl,0,10/2} \cdot \hat{\sigma}_{\hat{\beta}_2}] \equiv [\overline{\beta_2}; \underline{\beta_2}]_{90 \%}$$

$$95 \% \text{ I.C. para } \beta_2 = [\hat{\beta}_2 \pm t_{gl,0,05/2} \cdot \hat{\sigma}_{\hat{\beta}_2}] \equiv [\overline{\beta_2}; \underline{\beta_2}]_{95 \%}$$

$$99 \% \text{ I.C. para } \beta_2 = [\hat{\beta}_2 \pm t_{gl,0,01/2} \cdot \hat{\sigma}_{\hat{\beta}_2}] \equiv [\overline{\beta_2}; \underline{\beta_2}]_{99 \%}$$

Consulte **aquí** las tablas estadísticas. Tenga en cuenta que necesitamos tener los grados de libertad para el cálculo de los intervalos de confianza ( $gl = N - k$ )

# CONTENIDO

- 1 DISTRIBUCIONES MUESTRALES DE LOS ESTIMADORES MCO
- 2 PRUEBA DE HIPÓTESIS SOBRE UN SOLO PARÁMETRO DE POBLACIÓN: LA PRUEBA T
  - t-student
  - P-Value
- 3 INTERVALOS DE CONFIANZA
- 4 PRUEBA DE HIPÓTESIS SOBRE UNA COMBINACIÓN LINEAL SIMPLE DE PARÁMETROS
- 5 PRUEBA DE RESTRICCIONES LINEALES MÚLTIPLES: LA PRUEBA F
  - Prueba F
  - P-value
- 6 INFORME DE RESULTADOS DE REGRESIÓN

# MEDIDAS DE AJUSTE

Surgen algunas preguntas sobre el rendimiento del modelo.

- ¿Qué tan bien esa línea de regresión describe los datos?
- ¿Los regresores explican mucha o poca variación en la variable dependiente?
- ¿Están las observaciones dispersas o lejos de la línea de regresión?

El  $R^2$  y el error estándar de la regresión miden qué tan bien la línea de regresión MCO ... coincide con los datos. Estudiante: ¿Qué es el  $R^2$ ?

- el  $R^2$  mide la fracción de la varianza de  $y$  que se explica por los regresores
- $0 < R^2 < 1$

# MEDIDAS DE AJUSTE

Consideremos el siguiente modelo

$$Y_i = \hat{Y}_i + \hat{u}_i$$

reexpresamos arriba en términos de varianza

$$\text{Var}(Y_i) = \text{Var}(\hat{Y}_i) + \text{Var}(\hat{u}_i)$$

equivalentemente

$$\frac{\text{Var}(\hat{Y}_i)}{\text{Var}(Y_i)} + \frac{\text{Var}(\hat{u}_i)}{\text{Var}(Y_i)} = 1$$

o

$$\frac{\text{Var}(\hat{Y}_i)}{\text{Var}(Y_i)} = 1 - \frac{\text{Var}(\hat{u}_i)}{\text{Var}(Y_i)}$$

# MEDIDAS DE AJUSTE

Por lo tanto

$$R^2 = \frac{\text{Var}(\hat{u}_i)}{\text{Var}(Y_i)} = 1 - \frac{SCR}{SCT}$$

Ahora, necesitamos definir la **Suma Cuadrado de la Regresión (SCR)** y **Suma Cuadrada del Total (SCT)**.

$$SCT = \sum_{i=1}^n (Y_i - \bar{Y})^2 \quad (SCT)$$

$$SCR = \sum_{i=1}^n \hat{\mu}_i^2 \quad (SCR)$$

Por lo tanto, si la varianza del error es igual a la varianza de  $Y$ , eso significa que nuestro modelo no tiene poder de predicción. Eso implica  $R^2 = 0$ . Si nuestro modelo puede explicar la mayoría de los cambios de  $y$ , entonces  $R^2 \rightarrow 1$

# MEDIDAS DE AJUSTE: EJEMPLO I

- 1 En el ejemplo relativo a la estimación de una función de producción para Perú.

$$Q = e^{\alpha_0} K^{\alpha_k} L^{\alpha_l}$$

el  $R^2 = 0,80$ . Eso significa que el 80 % de los cambios en la producción se deben a cambios en el capital y el trabajo.

- 2 Tenemos los siguientes datos  $y = [40 \ 55 \ 25 \ 5 \ 10]'$ . Su querido profesor quiere que estimen el siguiente modelo  $y_t = \beta_0 + u_t$  utilizando el estimador MCO. Específicamente;
  - ¿Cuál es la estimación de  $\beta_0$
  - ¿Cuál es el  $R^2$ ?

## MEDIDAS DE AJUSTE: EJEMPLO II

- 1 De las cuentas nacionales, tenemos la siguiente identidad  $Y = C + I + G + XM$ . Un estudiante que reprobó la econometría propuso el siguiente modelo para evaluar el impacto del consumo en el PIB ( $Y$ )

$$Y_t = \beta_0 + \beta_1 C_t + \dots + \beta_5 M_t + u_t$$

- ¿Cuál es la media de  $\widehat{u}^2$ ?
  - ¿Cuál es el  $R^2$ ?
- 2 el siguiente modelos

$$M_1 : Y_i = \beta_0 + \beta_1 X_{1i} + u_i$$

$$M_2 : Y_i = \gamma_0 + \gamma_1 X_{1i} + \gamma_2 X_{2i} + u_i$$

El  $R^2$  de  $M_1$  y  $M_2$  son 0.701 y 0.80 respectivamente.  
¿Qué modelo es mejor?

# UNA ADVERTENCIA SOBRE $R^2$

- 1 El  $R^2$  aumenta cuando se agrega una nueva variable, por lo tanto, un aumento en el  $R^2$  no significa que agregar una nueva variable realmente mejora el ajuste del modelo.
- 2 De hecho, aunque la nueva variable no es significativa,  $R^2$  aumenta.
- 3 Un mal investigador puede inflar el ajuste del modelo agregando variables irrelevantes al modelo empírico.
- 4  $R^2$  es útil para mostrar el poder de explicación de su modelo, pero no para comparar.



# UNA ALTERNATIVA: $R^2$ AJUSTADO O $R^2$ ADJ

Tenemos una alternativa: el  $R^2$  ajustado

$$R^2 = 1 - \frac{N-1}{N-k} \frac{SCR}{SCT}$$

Algunas observaciones sobre esta medida de ajuste o ajuste

- 1 El  $R^2$ -ajustado siempre es más bajo que  $R^2$
- 2 Agregar un regresor tiene dos efectos opuestos en  $R^2$ -ajustado
- 3 El  $R^2$ -ajustado puede ser negativo

Una advertencia con respecto a esta medida de ajuste.

- 1 La medida de  $R^2$ -ajustado aumenta (disminuye) cuando el cuadrado del valor  $t$  realmente calculado, relacionado con la variable nueva o adicional, es mayor (menor) que uno.
- 2 Al final,  $R^2$ -ajustado también es útil para mostrar el poder de explicación de su modelo y eso tiene cierto poder de comparación, pero también es débil.

# CONTENIDO

- 1 DISTRIBUCIONES MUESTRALES DE LOS ESTIMADORES MCO
- 2 PRUEBA DE HIPÓTESIS SOBRE UN SOLO PARÁMETRO DE POBLACIÓN: LA PRUEBA T
  - t-student
  - P-Value
- 3 INTERVALOS DE CONFIANZA
- 4 PRUEBA DE HIPÓTESIS SOBRE UNA COMBINACIÓN LINEAL SIMPLE DE PARÁMETROS
- 5 PRUEBA DE RESTRICCIONES LINEALES MÚLTIPLES: LA PRUEBA F
  - Prueba F
  - P-value
- 6 INFORME DE RESULTADOS DE REGRESIÓN

# CONTENIDO

- 1 DISTRIBUCIONES MUESTRALES DE LOS ESTIMADORES MCO
- 2 PRUEBA DE HIPÓTESIS SOBRE UN SOLO PARÁMETRO DE POBLACIÓN: LA PRUEBA T
  - t-student
  - P-Value
- 3 INTERVALOS DE CONFIANZA
- 4 PRUEBA DE HIPÓTESIS SOBRE UNA COMBINACIÓN LINEAL SIMPLE DE PARÁMETROS
- 5 PRUEBA DE RESTRICCIONES LINEALES MÚLTIPLES: LA PRUEBA F
  - Prueba F
  - P-value
- 6 INFORME DE RESULTADOS DE REGRESIÓN

## INFERENCIA 2: PRUEBA DE HIPÓTESIS CONJUNTA

Consideremos nuevamente el siguiente modelo (o PGD) con una constante y más de un regresor

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + u_i$$

en particular, podemos estar interesados en probar la importancia conjunta de  $\beta_1$  y  $\beta_2$ . Por ejemplo

$$H_0 : \beta_1 = 0; \beta_2 = 0$$

$$H_a : \beta_j \neq 0 \text{ al menos un } j$$

¿Por qué podemos estar interesado en probar la significancia de coeficiente múltiples al mismo tiempo?

## INFERENCIA 2: PRUEBA DE HIPÓTESIS CONJUNTA

Aquí la respuesta:

- Variables de interés; ocurrencia conjunta de variables aleatorias.
- Importancia del modelo. En el caso de una prueba de significancia global: un modelo con constante versus un modelo con regresores.
- Una prueba de significancia multivariante teniendo en cuenta la correlación entre variables aleatorias.

# PRUEBA F

- La prueba F permite determinar, si en conjunto, todas las variables incluidas en el modelo explican a la variable analizada.
- Más concretamente, dada la regresión:
$$y = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \dots + \hat{\beta}_k x_k + \hat{u}$$
- La Hipótesis nula que se plantea es  $\beta_1 = \beta_2 = \dots = \beta_k = 0$
- Es decir, que todos los parámetros poblacionales, excepto el intercepto, tienen un valor poblacional de cero.
- En términos sencillos lo que se pregunta la prueba F es si incluir un conjunto de variables explicativas le gana a una regresión ingenua ( $y = \hat{\beta}_0 + \hat{u}$ )

# INFERENCIA II: ¿Z O T-STUDENT? ¡NO!, ¡DISTRIBUCIÓN F!

En este caso, usamos la distribución F. El estadístico es:

$$F_{cal} = \frac{(SCR_R - SCR_{NR})}{SCR_{NR}} \frac{N - k}{q}$$

Por ejemplo, en el caso de una prueba de significancia global, el modelo restringido tiene en cuenta la restricción bajo la hipótesis nula

$$Y_i = \hat{\gamma}_0 + \hat{\epsilon}_i \quad (\text{restringido})$$

El modelo no restringido es el original

$$Y_i = \hat{\beta}_0 + \hat{\beta}_1 X_{1i} + \hat{\beta}_2 X_{2i} + \hat{u}_i \quad (\text{no restringido})$$

es el número de restricciones impuestas en el modelo original. Luego contrastamos esa F realmente calculada con valores críticos o simplemente calculamos el valor p asociado a esa prueba (es decir,  $PR(F > F_{cal})$ )

## INFERENCIA II: EXPRESIÓN ALTERNATIVA

En el caso de una prueba de hipótesis global, podemos re-expresar la expresión de la prueba  $F$  como lo siguiente:

$$F_{cal} = \frac{R_{NR}^2 - R_r^2}{1 - R_{NR}^2} \cdot \frac{N - k}{q}$$

En el caso de probar todos los coeficientes que aceptan la constante son cero (en términos estadísticos), tenemos la siguiente expresión

$$F_{cal} = \frac{R_{NR}^2}{1 - R_{NR}^2} \cdot \frac{N - k}{q}$$



# EJEMPLO I

Tenemos el siguiente modelo

$$T = \hat{\beta}_0 + \hat{\beta}_1 STR + \hat{\beta}_2 EXP + \hat{\beta}_3 PctEL + \hat{u} \quad R^2 = 0,4366$$

Evaluamos la siguiente hipótesis

$$H_0 : \beta_1 = 0, \beta_2 = 0$$

$$H_1 : \beta_j \neq 0 \text{ al menos un } j$$

Eso implica estimar el siguiente modelo restringido:

$$TS = \hat{\gamma}_0 + \hat{\gamma}_3 PctEL + \hat{\epsilon} \quad R^2 = 0,4149$$

# EJEMPLO I

Calculamos el  $F_{cal}$

$$\begin{aligned} F_{cal} &= \frac{0,4366 - 0,4149}{1 - 0,4366} \cdot \frac{420 - 4}{2} \\ &= 8,0114 \end{aligned}$$

luego contrastamos que  $F$  “calculado realmente” con valores críticos, en este caso el valor crítico del 5 % viene dado por  $F(n_1, n_2) \equiv F(q, N - k) = F(2, 438) = 3,00$ . Por tanto, rechazamos la hipótesis nula de que ambos coeficientes son cero en términos estadísticos.

## EJEMPLO II

Tenemos la siguiente estimación de una función de producción

$$\ln Q_i = \hat{\beta}_0 + \hat{\beta}_1 \ln K_i + \hat{\beta}_2 \ln L_i + \hat{u}_i \quad R^2 = 0,8$$

realizamos una prueba de significancia conjunta sobre las elasticidades del capital y el trabajo, es decir,  $H_0 : \hat{\beta}_1 = \hat{\beta}_2 = 0$  y  $H_1 : \hat{\beta}_j \neq 0$  al menos una  $j$ . Calculamos el estadístico  $F$

$$\begin{aligned} F_{cal} &= \frac{0,8}{1 - 0,8} \cdot \frac{51 - 3}{2} \\ &= 96 \end{aligned}$$

luego contrastamos que  $F$  “calculado realmente” con valores críticos, en este caso el valor crítico del 1 % viene dado por  $F(n_1, n_2) \equiv F(q, N - k) = F(2, 48) \approx 5,20$ . Por tanto, rechazamos la hipótesis nula de que ambos coeficientes son cero en términos estadísticos.

## PRUEBA F: RESUMEN DE PASOS

- Calcular las estimaciones de MCO.
- Enuncie la hipótesis a probar.
- Calcular el SSR o  $R^2$  de modelos restringidos y no restringidos.
- Calcular la estadística F o F. calculada realmente".
- Calcular el valor P o simplemente concluya utilizando valores críticos en algún nivel de significancia.
- La interpretación es muy importante, ¡no te pierdas ese paso !.

# CONTENIDO

- 1 DISTRIBUCIONES MUESTRALES DE LOS ESTIMADORES MCO
- 2 PRUEBA DE HIPÓTESIS SOBRE UN SOLO PARÁMETRO DE POBLACIÓN: LA PRUEBA T
  - t-student
  - P-Value
- 3 INTERVALOS DE CONFIANZA
- 4 PRUEBA DE HIPÓTESIS SOBRE UNA COMBINACIÓN LINEAL SIMPLE DE PARÁMETROS
- 5 PRUEBA DE RESTRICCIONES LINEALES MÚLTIPLES: LA PRUEBA F
  - Prueba F
  - P-value
- 6 INFORME DE RESULTADOS DE REGRESIÓN

# P-VALUE

- Así como el estadístico T, la prueba F también tiene asociado un P-Value, el cual tiene la misma interpretación práctica: si es menor que 0.05 se rechaza la hipótesis nula de que las variables explicativas no sirven para explicar a  $y$

# CONTENIDO

- 1 DISTRIBUCIONES MUESTRALES DE LOS ESTIMADORES MCO
- 2 PRUEBA DE HIPÓTESIS SOBRE UN SOLO PARÁMETRO DE POBLACIÓN: LA PRUEBA T
  - t-student
  - P-Value
- 3 INTERVALOS DE CONFIANZA
- 4 PRUEBA DE HIPÓTESIS SOBRE UNA COMBINACIÓN LINEAL SIMPLE DE PARÁMETROS
- 5 PRUEBA DE RESTRICCIONES LINEALES MÚLTIPLES: LA PRUEBA F
  - Prueba F
  - P-value
- 6 INFORME DE RESULTADOS DE REGRESIÓN

# REFERENCIAS



Referencia 1



Referencia 2. *colocar alguna referencia*



Referencia 3. *colocar alguna referencia*



## Capítulo 04

## └ Informe de resultados de regresión

## └ Referencias

## REFERENCIAS




Referencia 1

Referencia 2. *colocar alguna referencia*Referencia 3. *colocar alguna referencia*

- Agregar alguna nota

# ECONOMETRÍA BÁSICA

## CAPÍTULO 04: MODELO DE REGRESIÓN LINEAL MÚLTIPLE-INFERENCIA

José Valderrama & Freddy Rojas  
jtvalderrama@gmail.com & frojasca@gmail.com   
Universidad Católica Santo Toribio de Mogrovejo

Septiembre de 2021